Многомерни и битови индекси. Дървовидни структури за многомерни данни в MySQL

Валентина Динкова, ф.н.71112

3 юни 2010 г.

1 GIS и разширението на MySQL за пространствени данни

GIS означава Географска Информационна Система и е един от най-очевидните примери за пространствени данни. От там идва и главната инициатива в БД да се пазят многомерни данни.
OGC (Open Geospatial Consorcium) е организация, която работи по стандартизирането на различни области на GIS. Един такъв стандарт е и спецификацията за SQL, която определя разширението на SQL базирани релационни бази данни, което да използва GIS обекти и операции.

OGC работи в 4 важни области:

- типове данни;
- операции;
- възможност да се подават като вход и да се извеждат GIS данни;
- индексиране на пространствени данни.

Друга важна област са метаданните. Може да се пазят например данни за координатната система. MySQL за момента поддържа само декартовата координатната система.

2 Стандартът, използван от почти всички SQL бази данни с пространствено разширение, включително и MySQL OpenGIS

Тук са показани типовете от стандарта.

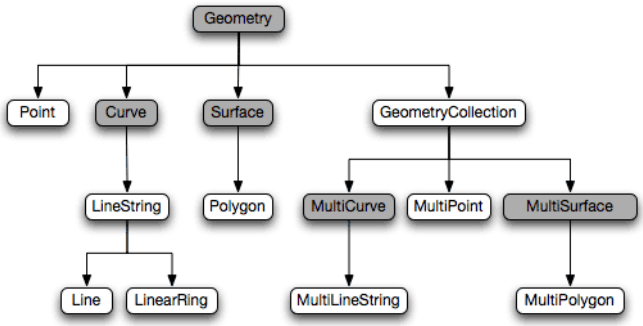

Типовете, отбелязани в сиво са абстрактни и обекти от тези типове не могат да се създават. Това не означава, че не може да имаме атрибут от този тип, а че не можем да слагаме стойности от този тип в дадената колона. Например можем да създадем атрибут от тип Geometry и да пазим стойности от тип Point.

3 Пространствени индекси

Пространствените данни могат да се индексират също както останалите данни в MySQL. Но за да бъде индексирането ефективно, се използва пространствен тип индексиране, реализирано чрез R-дървета. MySQL използва R-дървета с квадратично разделяне.
Не всички engine-и поддържат многомерни индекси. Единствено MyISAM ги поддържа за MySQL. Той е и engine-а, с който по подразбиране идва MySQL.

3.1 R-дървета

R-дърветата (регионални дървета) са структури от данни, които наподобяват B-дърветата и се използват за многомерни данни. Корените на R-дървото отговарят на региони, които обикновено в практиката са правоъгълници или други прости форми. Вместо ключове, R-дървото има подрегиони, които представят съдържанието на дъщерните си корени.

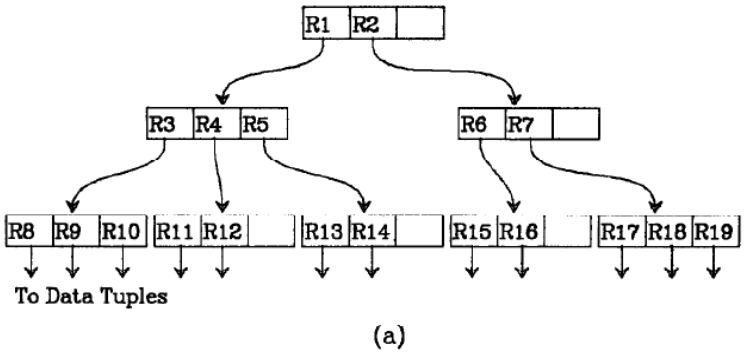

(a)

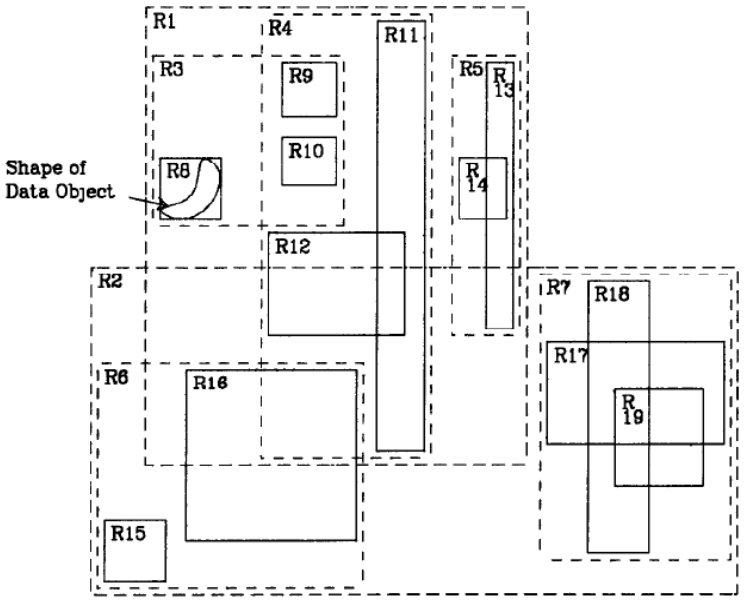

3.2 R-дървета с квадратично разделяне

При добавяне на нов запис методът на квадратичното разделяне се стреми да раздели листото на дървото на малки части, но не гарантира, че тези части са най-малките възможни.
Нека сме намерили листото, където трябва да добавим новия запис и нека $M =$ *"брой региони в листо"*.

1. Избираме 2 от $M + 1$ записа да бъдат първите елементи на двете нови листа, като избираме двойката,която би заела най-много място ако и двата елемента се поставят на едно място (двойката при която покриващия регион ще е най-голям). Намираме тази двойка като от областта покриваща двата записа изваждаме самите записи и искаме тази разлика да е най-голяма.

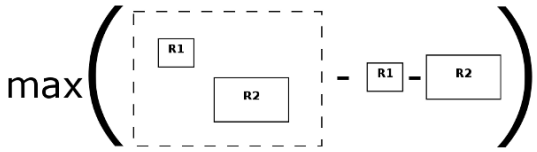

2. Останалите записи разделяме в двете листа един по един. На всяка стъпка разширяването, необходимо за добавянето на всеки от оставащите записи към всяко листо се изчислява и добавеният запис е този, който е показал най-голяма разлика спрямо двете листа.

Алгоритъмът $QuadraticSplit$ разделя множество от $M + 1$ индексни записа на две групи.

- (Избираме първия запис за всяка група)
  Прилагаме алгоритъма $PickSeeds$, за да изберем два записа за групите. Прибавяме всеки към съответната група.

- (Проверяваме дали сме приключили)
  Ако няма повече записи за добавяне - стоп. Ако едната група има толкова малко записи, че всички останали записи трябва да се прибавят към нея, за да има тя минималния брой, прибавяме ги и спираме.

- (Избираме запис, който да добавим)
  Прилагаме алгоритъм $PickNext$, за да изберем следващия запис който да добавим. Добавяме го към групата, чиито обграждащ правоъгълник се налага да бъде увеличен най-малко. Добавяме записа съм групата с по-малка област, след това до тази с по-малко записи, след това повтаряме от предишната стъпка.

Алгоритъмът $PickSeeds$ Избираме два записа да бъдат първите елементи на групите.

- (Изчисляваме неефективността за групиране)
  За всяка двойка записи E_1 и E_2, съставяме правоъгълник J, който включва E_1 и E_2. Изчисляваме $d = area(J) - area(E_1) - area(E_2)$.

- (Избираме най-неблагоприятната двойка)
  Избираме двойката, при която d е най-голямо.

Алгоритъмът $PickNext$ Избираме запис, който да добавим в една от групите

- (Определяме цената за прибавяне на всеки запис към всяка група) За всеки запис E, който не е добавен, изчисляваме d_1 = областта, с която се разширява първата група при добавяне на E. По същият начин изчисляваме d_2 за втората група.
- Избираме записа, при който е максимална разликата между d_1 и d_2.

3.3 Примери за пространствени индекси с $MySQL$

Създаваме таблицата map_test**, където** loc **е пространствен атрибут**. За сега все още не създаваме пространствен индекс по него.

```
mysql> create table map_test
    -> (
    ->   name varchar(100) not null primary key,
    ->   loc  geometry not null,
    -> );
Query OK, 0 rows affected (0.00 sec)
```

Чрез следната процедурата добавяме 30 000 реда

```
 mysql> CREATE PROCEDURE fill_points(IN size INT(10))
    -> BEGIN
    ->   DECLARE i DOUBLE(10,1) DEFAULT size;
    ->
    ->   DECLARE lon FLOAT(7,4);
    ->   DECLARE lat FLOAT(6,4);
    ->   DECLARE position VARCHAR(100);
    ->
    ->   DELETE FROM map_test;
    ->
    ->   WHILE i > 0 DO
    ->     SET lon = RAND() * 360 - 180;
    ->     SET lat = RAND() * 180 - 90;
    ->
    ->     SET position = CONCAT( 'POINT(', lon, ' ', lat, ')' );
    ->
    ->     INSERT INTO map_test(name, loc) VALUES ( CONCAT('name_', i), GeomFromText(posit
    ->
    ->     SET i = i - 1;
    -> END WHILE;
    -> END @
Query OK, 0 rows affected (0.08 sec)

mysql> delimiter ;
mysql> CALL fill_points(30000);
Query OK, 1 row affected (26.00 sec)
```

Заявка за проверка кои точки се съдържат в полигона

```
 mysql> SELECT name, AsText(loc) FROM map_test WHERE
    -> Contains(
    -> GeomFromText('POLYGON((0 0, 0 1, 1 1, 2 0, 0 0))'),
    -> loc) = 1;

+--------------+----------------------+
| name         | AsText(loc)          |
+--------------+----------------------+
| name_12768.0 | POINT(0.6646 0.7551) |
| name_14707.0 | POINT(1.8941 0.1449) |
| name_29530.0 | POINT(0.1938 0.0931) |
+--------------+----------------------+
3 rows in set (0.12 sec)
```

Сега създаваме пространствен индекс по атрибута loc

```
mysql> create spatial index ps_index on map_test(loc);
Query OK, 30000 rows affected (2.44 sec)
Records: 30000  Duplicates: 0  Warnings: 0
```

и отново правим същата заявка

```
 mysql> SELECT name, AsText(loc) FROM map_test WHERE
    -> Contains(
    -> GeomFromText('POLYGON((0 0, 0 1, 1 1, 2 0, 0 0))'),
    -> loc) = 1;

+--------------+----------------------+
| name         | AsText(loc)          |
+--------------+----------------------+
| name_12768.0 | POINT(0.6646 0.7551) |
| name_14707.0 | POINT(1.8941 0.1449) |
| name_29530.0 | POINT(0.1938 0.0931) |
+--------------+----------------------+
3 rows in set (0.05 sec)
```

Забелязва се, че когато има индекс същата заявка се изпълнява по-бързо.